



# Técnica de optimización no lineal aplicadas al diagnóstico médico de cáncer mamario


Mario Mallea

Maximiliano Ramírez

Hugo Rocha

4 enero, 2021

# Índice

- 
- 1 Introduction
  - 2 Motivación
  - 3 Formulación como problema de optimización
  - 4 Análisis del problema de optimización
  - 5 Análisis del problema de optimización
  - 6 Rutinas de Resolución
  - 7 Representación y caracterización de soluciones
  - 8 Representación y caracterización de soluciones
  - 9 Representación y caracterización de soluciones
  - 10 Conclusión

# Introduction


- A continuación se presenta nuestro trabajo sobre técnicas de optimización no lineal aplicados a la detección del cáncer mamario a partir de imágenes de biopsias de células tumorales. Logrando obtener una caracterización de la solución al problema de clasificación y por tanto una posible automatización del diagnóstico.

# Motivación

## El Cáncer en Cifras

A nivel mundial en el año 2012 cerca de 521.000 mujeres murieron a causa del cáncer de mama<sup>a</sup>.

<sup>a</sup>Global burden of cancer in womans



Biopsia con aguja fina de masa mamaria con presencia de células tumorales

# Formulación como problema de optimización.

## Hiperplano separador

- Un hiperplano separador es una superficie de codimensión 1<sup>a</sup> de decisión que separa las distintas clases que tiene el problema de clasificación. El hiperplano sera denotado por  $\mathcal{H}$  es de la forma:

$$w^T x + b = 0$$

<sup>a</sup>es decir, es un subespacio de una dimensión menos que el espacio en el que se trabaja

## Margen del Hiperplano

- El margen geométrico de un hiperplano  $\mathcal{H}$  con respecto a la data, se define como la distancia más corta de un punto de entrenamiento  $x_i$  al hiperplano  $\mathcal{H}$ .

## Hiperplano óptimo

- Consideraremos como hiperplano separador óptimo  $\mathcal{H}$  aquel que tiene el mayor margen posible

# Formulación como problema de optimización




Figure 1: Construcción del margen.

# Formulación como problema de optimización

## Formulación Formal del problema

$$\left\{ \begin{array}{l} \max_w \min_{x_i} \left| \langle x_i, \frac{w}{\|w\|} \rangle + b \right| \\ \text{s.t.: } \text{sign}(\langle x_i, w \rangle + b) = \text{sign}(y_i) \end{array} \right.$$



# Formulación como problema de optimización

## SVM duro

$$\left\{ \begin{array}{l} \min \quad \frac{1}{2} \|w\|^2 \\ \text{s.t.: } (\langle x_i, w \rangle + b)y_i \geq 1 \end{array} \right. \quad (1)$$

# Formulación como problema de optimización.

## Problema dual duro

- Veamos ahora que es posible obtener la formulación dual de nuestro problema de optimización dado por:

$$\begin{aligned} \max_{\alpha_i \geq 0} \quad & \sum_i^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle \\ \text{s.t.} \quad & \alpha_i \geq 0 \quad \forall i = 1, 2, \dots, n, \\ & \sum_{i=1}^n \alpha_i y_i = 0 \quad \forall i = 1, \dots, n \end{aligned} \tag{2}$$

# Formulación como problema de optimización.

¿Que hacer si se nos presente el siguiente caso?




Figure 2: Caso casi linealmente separable.

- Consideraremos que nuestros datos son casi linealmente separables si salvo una cantidad reducida con respecto a la data nuestro problema es linealmente separable.

# Formulación como problema de optimización.

## SVM blando

$$\begin{aligned} \min_{w, b, \xi} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \\ \text{s.t.} \quad & (\langle x_i, w \rangle + b) y_i \geq 1 - \xi_i, \\ & \xi_i \geq 0 \forall i = 1, \dots, n \end{aligned} \tag{3}$$

# Formulación como problema de optimización.

## Formulación SVM dual blando

$$\begin{aligned}
 & \max_{\alpha_i \geq 0} \quad \sum_i^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle \\
 & \text{s.t.} \quad C \geq \alpha_i \geq 0 \quad \forall i = 1, 2, \dots, n, \\
 & \quad \sum_{i=1}^n \alpha_i y_i = 0 \quad \forall i = 1, \dots, n
 \end{aligned} \tag{4}$$

### Observación



$$\sum_i^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle = \frac{1}{2} \alpha^T \Lambda \alpha + q^T \alpha \tag{5}$$

se tendrá que la matriz  $\Lambda \in \mathbb{R}^N \times \mathbb{R}^N$  es definida positiva, así la función a maximizar es cóncava, por lo que se tiene que el máximo del problema es único.

# Formulación como problema de optimización.

¿Que hacemos si ahora se nos presenta el siguiente caso?




Figure 3: Caso no linealmente separable.

- Consideraremos que nuestros datos son no linealmente separable cuando bajo ningún punto de vista es posible separar nuestros datos por medio de un hiperplano.

# Formulación como problema de optimización.

## Teorema de Cover

- Sea  $\phi : \mathbb{R}^d \rightarrow \mathbb{R}^D$ . Para cualquier conjunto de  $n \in \mathbb{Z}$ , ejemplos  $S = \{(x^{(l)}, y^{(l)})\}_{l=1}^n$ ,  $x^{(l)} \in \mathbb{R}^d$ ,  $y^{(l)} \in \{\pm 1\}$ , tenemos que  $\phi(S) = \{(\phi(x^{(l)}), y^{(l)})\}$  es linealmente separable con probabilidad:

$$P(n, D) = \frac{1}{2^{n-1}} \sum_{k=0}^{D-1} \binom{n-1}{k}$$

# Formulación como problema de optimización.




Figure 4: Caso linealmente separable en espacio de mayor dimensionalidad.

# Formulación como problema de optimización.

## Función Kernel

- Denominaremos funciones Kernel, a aquellas que cumplan con lo siguiente:

$$\kappa(x, y) = \langle \phi(x), \phi(y) \rangle \quad (6)$$

Dónde  $\phi$  es una función que va de  $X$  a un espacio de mayor dimensionalidad dotado de un producto interno.

# Formulación como problema de optimización.

## SVM dual blando Kernelizado

$$\begin{aligned} \max_{\alpha_i \geq 0} \quad & \sum_i^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \kappa(x_i, x_j) \\ \text{s.t.} \quad & C \geq \alpha_i \geq 0 \quad \forall i = 1, 2, \dots, n, \\ & \sum_{i=1}^n \alpha_i y_i = 0 \quad \forall i = 1, \dots, n \end{aligned} \tag{7}$$

# Formulación como problema de optimización

## Algunos Kernels populares

- Lineal:

$$k(x, x') = x^T x'$$

- RBF o Gaussiano de escala  $\gamma$ :

$$k(x, x') = e^{-\gamma ||x^T x'||^2}$$

- Polinomial de grado  $p$ , intercepto  $c_0$  y escala  $\gamma$ :

$$k(x, x') = (\gamma x^T x' + c_0)^p$$

- Laplaciano de escala  $\gamma$ :

$$k(x, x') = e^{-\gamma ||x^T x||_1}$$

# Análisis del problema de optimización

## Análisis de sensibilidad

- Problema de programación matemática perturbado

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \leq u_i \quad i = 1, \dots, m \end{aligned} \tag{8}$$

# Análisis del problema de optimización

## Análisis de sensibilidad

- Condición de optimalidad del problema perturbado

$$p^*(u) \geq p^*(0) - \alpha^{*T} u \quad (9)$$

## Análisis de sensibilidad

- $\alpha_i^*$  grande y  $u_i < 0 \implies p^*(u)$  aumentará demasiado
- $\alpha_i^*$  pequeño y  $u_i > 0 \implies p^*(u)$  no disminuye en gran medida

## Observación

A partir de (9) es posible deducir que la sensibilidad del problema viene dada por la magnitud del multiplicador de Lagrange asociado a cada restricción

# Análisis de sensibilidad

## SVM dual blando Kernelizado

$$\begin{aligned} \max_{\alpha_i \geq 0} \quad & \sum_i^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \kappa(x_i, x_j) \\ \text{s.t.} \quad & C \geq \alpha_i \geq 0 \quad \forall i = 1, 2, \dots, n, \\ & \sum_{i=1}^n \alpha_i y_i = 0 \quad \forall i = 1, \dots, n \end{aligned} \tag{10}$$

# Aproximación de support vectors

## Función de decisión

$$F(x) = \text{sign} \left( \sum_i (\alpha_i y_i \kappa(x_i, x)) + b^* \right) \quad (11)$$

Dónde

$$\begin{aligned} b^* &= |B|^{-1} \sum_{\ell} \left( y^{(\ell)} - w^T x^{(\ell)} \right) \\ &= |B|^{-1} \sum_{\ell} \left( y^{(\ell)} - \sum_{\ell'} \alpha_{\ell'} y^{(\ell')} \langle x^{(\ell')} x^{(\ell)} \rangle \right) \end{aligned} \quad (12)$$

## Observación

La función de decisión sólo depende de los multiplicadores de Lagrange no nulos.

# Rutinas de Resolución







## Problema de programación cuadrática

$$\begin{aligned}
 \min \quad & \frac{1}{2} \alpha^T P \alpha + q^T \alpha \\
 \text{s.t.} \quad & G \alpha \leq h, \\
 & A \alpha = b
 \end{aligned} \tag{13}$$

## Problema dual blando como uno de programación cuadrática

$$\begin{aligned}
 \max_{\alpha_i \geq 0} \quad & \sum_i^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \kappa(x_i, x_j) \\
 \text{s.t.} \quad & C \geq \alpha_i \geq 0 \quad \forall i = 1, \dots, n, \\
 & \sum_{i=1}^n \alpha_i y_i = 0 \quad \forall i = 1, \dots, n
 \end{aligned} \tag{14}$$

# Representación y caracterización de soluciones



# Representación y caracterización de soluciones




Figure 5: Matriz de Confusión: Kernel Lineal y regularización =100

# Representación y caracterización de soluciones




Figure 6: Matriz de Confusión: Kernel Gaussiano y regularización =100

# Conclusión

- Automatización del diagnóstico  $\implies$  grandes cantidades de datos.
- Ineficiencia en memoria para QP.
- SVM tiene lenta velocidad de convergencia.
- Solución: Reducción de datos  $\implies$  Propuesta: Estimar.

# Gracias